CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Dresden • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf die Anbindung von LLM-APIs an agentische Systeme, von Multi-Agenten-Pipelines mit Tool Use und MCP über RAG bis zu Evals gegen eine Ground Truth und Kostenkontrolle. Zuletzt alleinverantwortlicher Entwickler eines agentischen Wissensextraktionssystems für die deutsche Energiewirtschaft, mit soliden Grundlagen in Python-Entwicklung, REST-APIs und Deployment mit Docker auf AWS und Azure in Konzern- und Start-up-Umgebungen.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortlicher Entwickler einer LLM-basierten Wissensextraktions-Pipeline für die Energiewirtschaft, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indexierung; direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten.
- Entwicklung parallel arbeitender LangGraph-Agenten für Entitätsextraktion, Beziehungsanalyse und Konsolidierung sowie eines Reflection-Agenten zur Ergebnisprüfung, für regulatorische und technische Dokumente; Evals gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Entwicklung eines MCP-Servers (Model Context Protocol), der den Knowledge Graph KI-Agenten als Werkzeug (Tool Use) mit Latenzen im Millisekundenbereich bereitstellt, integriert in Claude Code und dort mit eigenen Skills und agentischen Workflows genutzt.
- Kostenkontrolle durch Vereinfachung: Wo Code ausreichte, Aufbau einer deterministischen (codebasierten) Pipeline statt LLM-Aufrufen für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt, Extraktionsgenauigkeit in Richtung 100 % gesteigert.
- Entwicklung von Expert Interface, einer Web-App (React-Frontend, Python-Microservices) auf Azure, in der Fachexperten Änderungen am Knowledge Graph prüfen und freigeben, bevor sie übernommen werden.
- **Tech-Stack: Python, LLM-APIs (LiteLLM), MCP, LangGraph, LangChain, RAG, GraphRAG, FastAPI, Docker, Kubernetes, Azure, Neo4j**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Analyse der Entscheidungsabläufe mit Stakeholdern aus dem Fachbereich und Beratung dazu, wo agentische KI sie unterstützen kann; Überführung der Anforderungen in ein konkretes Lösungskonzept.
- Umsetzung und Deployment eines KI-Agenten mit LangGraph, der Anfragen je nach Bedarf an eine Vektordatenbank-Suche, an allgemeine Inferenz oder an eine Zusammenfassungsfunktion weiterleitet.
- Entwicklung einer REST-API mit Python/FastAPI und eines React-Frontends, API-Tests mit Postman; Containerisierung mit Docker, Deployment auf AWS mit CDK, Versionierung mit Git in GitLab inklusive CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, REST, Docker, Git, GitLab CI/CD, AWS (CDK, EC2, Lambda), React, Postman**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evals für das RAG-System PrismaChat: Antwortqualität und Retrieval mit RAGAS und PytrecEval gegen eine von Chemikern erstellte Ground Truth gemessen.
- Aufbau der AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die automatisierte RAG-Evaluierung.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks; Konzeption von RAG-Pipelines mit Chunking, Vektordatenbanken, Indexierung und Fine-Tuning für besseres Retrieval.
- **Tech-Stack: Python, RAGAS, PytrecEval, LangChain, Hugging Face Transformers, Azure AI Search, AWS CDK**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität) aus Zeitreihen-Prozessdaten, mit Streamlit-Dashboard für Chemiker.

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Python-Entwicklung von ARIMA-, SARIMA-, XGBoost-, FB-Prophet- und LSTM-Modellen zur Lastprognose für Elektrofahrzeuge; LSTM mit 96 % Testgenauigkeit und guter Leistung auf ungesehenen Daten.

PROJEKTE

Projekt: Ops MCP Server | MCP | TypeScript | Slack | GitHub | HubSpot API | Notion

- MCP-Server, der Claude und einem Slack-Bot typisierte, rechtegeprüfte Werkzeuge über HubSpot-Deals, offene GitHub-Pull-Requests und eine RAG-Suche über Notion-Prozessdokumente gibt, damit Teamfragen aus Live-Daten beantwortet werden.
- Slack-Webhooks mit Signaturprüfung und OAuth, Zod-Schemas für jedes Werkzeug, rollenbasierter Zugriff nach Least Privilege, Secrets nur über Umgebungsvariablen; Betrieb mit Docker und systemd auf einem Linux-Server, CI mit GitHub Actions inklusive kleinem Eval-Set, als Claude-Code-Plugin paketiert.

TECHNISCHE KENNTNISSE

- **LLM-Integration & Agenten:** LLM-APIs (LiteLLM), Prompt Engineering, Tool Use/Function Calling, MCP, LangGraph, LangChain, Claude Code
- **Wissensbasis & Suche:** RAG, GraphRAG, Vektorsuche (Qdrant, Pinecone, Azure AI Search), Neo4j, Postgres
- **Evals & Qualität:** Evals gegen Ground Truth, RAGAS, PytrecEval, Reflection-Agenten, API-Tests (Postman)
- **Programmierung & APIs:** Python, SQL, FastAPI, REST-APIs, Python-Microservices, React
- **Betrieb & Deployment:** Docker, Kubernetes, Git, GitLab CI/CD, Azure, AWS (CDK, Lambda, EC2, SQS)
- **Machine Learning:** Scikit-Learn, PyTorch, TensorFlow, XGBoost, Hugging Face, Fine-Tuning (QLoRA)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau — Aug. 2017 – Juli 2021
Nebenfach Informatik (Minor in Computer Science & Engineering)
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)