CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Frankfurt am Main • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in KI-Engineering und Softwareentwicklung. Spezialisiert auf Evaluation und Qualitätssicherung von GenAI-Systemen, von der automatisierten RAG-Evaluation bis zur systematischen Prüfung agentischer LLM-Workflows gegen eine Ground Truth mit klaren Qualitätsmetriken. Zuletzt alleinverantwortlicher Entwickler eines agentischen Wissensextraktionssystems für die deutsche Energiewirtschaft, mit fundierter Basis in Python-Entwicklung, API-Tests, CI/CD und Cloud-Deployment auf AWS und Azure.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Entwicklung und systematische Evaluation eines Multi-Agenten-Systems mit LangGraph (Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection-Agent parallel) für regulatorische und technische Dokumente: Messung gegen eine aus SAP-Systemen abgeleitete Ground Truth mit Precision und Recall als Qualitätsmetriken, durch gezielte Anpassung von Prompting und Agenten von 33 %/45 % auf 93 %/90 % gesteigert.
- Alleinverantwortliche Entwicklung der gesamten Wissensextraktions-Pipeline (Datenaufnahme, Chunking, Prompt Engineering, Indexierung mit agentischen, deterministischen und monolithischen Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der Energiewirtschaft.
- Entwicklung einer deterministischen (codebasierten) Pipeline für einen zweiten, volumenstarken Datenstrom: prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt, Extraktionsgenauigkeit in Richtung 100 % gesteigert.
- Entwicklung eines MCP-Servers (Model Context Protocol), über den KI-Agenten per Tool Calling auf den Knowledge Graph zugreifen, mit Latenzen im Millisekundenbereich; integriert in Claude Code.
- Entwicklung von Expert Interface, einer Web-App (React, Python-Microservices) auf Azure, in der Fachexperten Änderungen am Knowledge Graph prüfen und freigeben, bevor sie übernommen werden.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, Prompt Engineering, RAG, GraphRAG, MCP, FastAPI, Docker, Kubernetes, Azure, Neo4j, MongoDB, Postgres**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Analyse der Entscheidungsprozesse mit Stakeholdern aus dem Fachbereich, Beratung zum Einsatz agentischer KI und Überführung der Anforderungen in ein technisches Lösungskonzept.
- Entwicklung und Deployment einer agentischen GenAI-Anwendung mit LangGraph, die Anfragen an eine Suche in der Vektordatenbank, an Inferenz oder an eine Zusammenfassung weiterleitet; React-Frontend, Python/FastAPI-Backend, API-Tests mit Postman.
- Containerisierung mit Docker, Deployment auf AWS mit CDK, CI/CD in GitLab.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, Postman, React, Docker, GitLab CI/CD, AWS (CDK, EC2, Lambda)**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval des RAG-Systems PrismaChat mit RAGAS und PytrecEval: Vergleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Infrastruktur für die RAG-Evaluation (Lambda, SQS, DynamoDB) mit CDK; Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks interner Chemiedaten.

- Entwicklung von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indexierung und Fine-Tuning von Modellen für besseres Retrieval.
- **Tech-Stack: Python, RAGAS, PytrecEval, LangChain, Hugging Face Transformers, PyTorch, Azure AI Search, AWS (Lambda, SQS, DynamoDB, S3, CDK)**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität) aus Zeitreihen-Prozessdaten; Benchmarking gegen empirische Kurvenanpassung.

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-, FB-Prophet- und LSTM-Modellen zur Lastprognose für Elektrofahrzeuge in Python; LSTM mit 96 % Testgenauigkeit und guter Leistung auf ungesehenen Daten.

PROJEKTE

Projekt: Agent Eval Harness | Python | LangGraph | pytest | GitHub Actions | OpenTelemetry

- AI Test Harness für einen Agenten für Conversational AI mit Tool Calling über eine gemockte API: Golden Datasets und Golden Conversations (Multi-Turn, Edge Cases, Handover an einen Menschen) für automatisierte Regression; deterministische Prüfungen (JSON-Schema, Tool-Calling-Payloads, API-Status) vor LLM-as-a-Judge.
- Security- und Robustheitstests für Prompt Injection, Data Leakage, Rollen-/Rechteprüfung der Tools und fehlerhafte Eingaben; Qualitätsmetriken als Passrate mit Konfidenzintervall über mehrere Läufe.
- Teststrategie nach Testpyramide bis zu End-to-End-Tests; Testautomatisierung in der CI/CD-Pipeline (GitHub Actions) mit Quality Gates und Releasekriterien; Mocking von LLM-Aufrufen, Monitoring per Tracing mit OpenTelemetry und Arize Phoenix.

TECHNISCHE KENNTNISSE

- **KI-Evaluation & Qualität:** RAG-Evaluation (RAGAS, PytrecEval), Ground-Truth-Evaluation, Qualitätsmetriken (Precision, Recall), Benchmarking von Embedding-Modellen, API-Tests (Postman)
- **GenAI & Agenten:** LLMs, Prompt Engineering, RAG, GraphRAG, Tool Calling (MCP), Multi-Agenten-Systeme, LangGraph, LangChain, LiteLLM, Hugging Face Transformers, Fine-Tuning (QLoRA), Claude Code
- **Programmierung:** Python, SQL, FastAPI, REST-APIs, Python-Microservices, React (Grundkenntnisse), Streamlit
- **CI/CD, Cloud & Methoden:** GitLab CI/CD, Git, Docker, Kubernetes, AWS (CDK, Lambda, SQS, DynamoDB, S3, EC2), Azure, Agile
- **Daten & ML:** Postgres, MongoDB, Neo4j, Vektordatenbanken (Qdrant, Pinecone, Azure AI Search), Scikit-Learn, PyTorch, TensorFlow, Pandas

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau — Aug. 2017 – Juli 2021
Nebenfach Informatik (Minor in Computer Science & Engineering)
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)