CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Hamburg • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf LLM- und RAG-Lösungen und deren wirtschaftliche Überführung in den Betrieb, von CI/CD-Pipelines und Infrastructure-as-Code bis zum Cloud-Deployment auf Azure und AWS. Zuletzt alleinverantwortlicher Entwickler eines agentischen Wissensextraktionssystems für die deutsche Energiewirtschaft, mit fundierter Basis in Machine Learning, Python-Entwicklung und der Beratung von Fachbereichen zu KI-Use-Cases.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche Entwicklung eines LLM-basierten Wissensextraktionssystems für die deutsche Energiewirtschaft, von der Datenaufnahme über Chunking und Prompt Engineering bis zur Indexierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten.
- Entwicklung eines Multi-Agenten-Systems mit LangGraph (Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection-Agent parallel) für regulatorische und technische Dokumente; systematische Qualitätsprüfung gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Wirtschaftlicher Betrieb: deterministische (codebasierte) Pipeline für einen zweiten, volumenstarken Datenstrom entwickelt und damit ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt, und die Extraktionsgenauigkeit in Richtung 100 % verbessert.
- Entwicklung und Bereitstellung der Web-App Expert Interface (React, Python-Microservices) auf Azure mit Freigabeprozess, in dem Fachexperten Änderungen am Knowledge Graph prüfen und freigeben.
- Entwicklung eines MCP-Dienstes (Model Context Protocol), der den Knowledge Graph mit Latenzen im Millisekundenbereich für KI-Agenten bereitstellt, integriert in Claude Code.
- **Tech-Stack: Azure, Docker, Kubernetes, Python, LLMs, RAG, GraphRAG, LangGraph, LangChain, LiteLLM, MCP, FastAPI, React, Neo4j, MongoDB, Postgres**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Beratung von Stakeholdern aus dem Fachbereich bei der Bewertung eines konkreten KI-Use-Cases: Analyse ihrer Entscheidungsprozesse, Empfehlung, wo agentische KI sie unterstützen kann, und Überführung der Anforderungen in ein technisches Lösungskonzept.
- Containerisierung mit Docker und Bereitstellung auf AWS als Infrastructure-as-Code mit CDK; Versionierung mit Git und CI/CD-Pipelines in GitLab.
- Umsetzung einer agentischen KI-Anwendung mit LangGraph, die Anfragen an Vektordatenbank-Suche, LLM-Inferenz oder Zusammenfassung weiterleitet (React, Python/FastAPI).
- **Tech-Stack: AWS CDK (Infrastructure-as-Code), GitLab CI/CD, Git, Docker, Python, LangGraph, LangChain, FastAPI, React, Postman**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 Leverkusen

- Aufbau von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indexierung und Fine-Tuning von Modellen für ein besseres Retrieval.
- Automatisierte Evaluierung des RAG-Systems PrismaChat mit RAGAS und PytrecEval gegen eine Ground Truth von Chemikern; Infrastruktur auf AWS (Lambda, SQS, DynamoDB) als Infrastructure-as-Code mit CDK.

- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks interner Chemiedaten.
- **Tech-Stack: Azure AI Search, AWS CDK, Python, LangChain, Hugging Face Transformers, PyTorch, RAGAS, PytrecEval**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität) aus Zeitreihen-Prozessdaten.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sept. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-, FB-Prophet- und LSTM-Modellen zur Lastprognose für Elektrofahrzeuge; LSTM mit 96 % Testgenauigkeit und guter Leistung auf ungesehenen Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Azure AI RAG Starter-Kit | Terraform | Azure DevOps | Azure OpenAI | Azure AI Search

- Wiederverwendbare Terraform-Module und YAML-Pipelines in Azure DevOps, die eine RAG-Referenzlösung pro Umgebung reproduzierbar bereitstellen: Azure OpenAI, Azure AI Search und Key Vault hinter Private Endpoints in einem eigenen VNet, Zugriff über Entra ID (Managed Identity), Monitoring mit Azure Monitor und Application Insights.
- Python/FastAPI-Referenz-App für Fragen zu öffentlichen Netzanschluss-Dokumenten mit Quellenangaben; RAG-Evaluierung (RAGAS) als Qualitätstor in der Pipeline, Kosten-Tags und Budget-Alarme pro Umgebung, als Templates mit Dokumentation für weitere Teams.

TECHNISCHE KENNTNISSE

- **Cloud & DevOps:** Azure (Deployment von Web-Apps, Azure AI Search), Git, CI/CD-Pipelines (GitLab CI/CD), Infrastructure-as-Code (AWS CDK), Docker, Kubernetes, AWS (Lambda, EC2, SQS, S3, DynamoDB, VPC)
- **KI & LLMs:** LLMs, RAG-Architekturen, GraphRAG, LangChain, LangGraph, Multi-Agenten-Systeme, MCP, LiteLLM, Prompt Engineering, Fine-Tuning (QLoRA), Evaluierung (RAGAS, PytrecEval)
- **Programmierung:** Python, SQL, FastAPI, REST-APIs, Python-Microservices, React
- **Daten & ML:** Postgres, MongoDB, Neo4j, Vektordatenbanken (Qdrant, Pinecone), Scikit-Learn, PyTorch, XGBoost

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau — Aug. 2017 – Juli 2021
Nebenfach Informatik (Minor in Computer Science & Engineering)
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKAT

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)