CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 München • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf Anwendungen mit Large Language Models (LLMs) und agentische Workflows, von der Anforderungsanalyse mit Fachbereichen über LLM-Orchestrierung und Tool Calling bis zum Cloud-Deployment. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, gestützt auf Erfahrung in der KI-Beratung.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche Entwicklung einer KI-Lösung zur Wissensextraktion von der fachlichen Analyse bis zur Übergabe: Datenaufnahme, Chunking, Prompt Engineering und Indexierung; direkt dem CTO unterstellt, Anforderungen gemeinsam mit SAP-Fachexperten der Energiewirtschaft erarbeitet.
- Multi-Agent-System mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung, Reflection) mit strukturierten Ausgaben für regulatorische und technische Dokumente; Precision/Recall gegen eine Ground Truth aus SAP-Systemen von 33 %/45 % auf 93 %/90 % gesteigert.
- Abwägung zwischen Qualität und Kosten: deterministische (codebasierte) Pipeline statt LLM für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null gesenkt, Genauigkeit annähernd 100 %.
- MCP-Server (Model Context Protocol) als Tool-Schnittstelle zum Knowledge Graph mit Latenzen im Millisekundenbereich, angebunden an Claude Code für agentische Entwicklungs-Workflows.
- Expert Interface: Web-App (React, Python-Microservices) auf Azure, in der Fachanwender Änderungen am Knowledge Graph prüfen und freigeben, bevor sie wirksam werden.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, MCP, FastAPI, Neo4j, MongoDB, Postgres, RAG, GraphRAG, Docker, Kubernetes, Azure, React**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Analyse von Entscheidungsprozessen mit Business-Stakeholdern, Beratung zu sinnvollen Einsatzmöglichkeiten agentischer KI und Übersetzung der Anforderungen in ein technisches Lösungskonzept.
- Entwicklung und Deployment einer agentischen KI-Anwendung mit LangGraph, die Anfragen an Vektordatenbank-Suche, LLM-Inferenz oder Zusammenfassung weiterleitet (LLM-Orchestrierung); Backend-Services in Python mit FastAPI, React-Frontend und API-Tests mit Postman.
- Containerisierung mit Docker, Deployment auf AWS mit CDK, Versionierung und CI/CD in GitLab.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD, React**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 Leverkusen

- Automatisierte Evaluierung von Antwortqualität und Retrieval des RAG-Systems PrismaChat mit RAGAS und PytrecEval gegen eine von Chemikern erstellte Ground Truth, auf AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK.
- Benchmarking mehrsprachiger Embedding-Modelle (NLP) auf über 1 Mio. Daten-Chunks interner Chemiedaten; Konzeption von RAG-Pipelines und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, RAGAS, PytrecEval, LangChain, Hugging Face Transformers, PyTorch, AWS CDK, Azure AI Search**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Training und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Syntheseergebnissen aus Zeitreihen-Prozessdaten; Streamlit-Dashboard, in dem Chemiker Parameteränderungen vor einer Charge simulieren.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von Zeitreihenmodellen (ARIMA, SARIMA, XGBoost, FB Prophet, LSTM) zur Lastprognose für Elektrofahrzeuge; LSTM mit 96 % Testgenauigkeit.

PROJEKTE

Projekt: LLM Gateway | Python | FastAPI | LLM APIs

- Anbieterunabhängige API-Schicht über mehrere LLM-Anbieter mit Token-Budgets, Streaming, Timeouts, Retries, Fehlerhandling und Fallbacks zwischen Anbietern; Kostenkontrolle durch Protokollierung von Latenz, Token-Verbrauch und Kosten je Anfrage.
- Metrik-Endpunkt für Kosten pro Anfrage, Latenz-Perzentile und Evaluierungs-Erfolgsquote; Tests und Evaluierung laufen in CI.

TECHNISCHE KENNTNISSE

- **LLMs & Agenten:** LLM-Orchestrierung mit LangGraph und LangChain, Tool Calling über MCP, Multi-Agent-Systeme, strukturierte Ausgaben, LiteLLM, RAG, GraphRAG, Prompt Engineering, Evaluierung (RAGAS, PytrecEval), NLP mit Hugging Face Transformers
- **Backend & APIs:** Python, Backend-Services mit FastAPI, Python-Microservices, REST-APIs, SQL, API-Tests (Postman), React (Grundkenntnisse)
- **Cloud & DevOps:** Azure, AWS (EC2, Lambda, SQS, DynamoDB, S3, CDK), Docker, Kubernetes, Git, GitLab CI/CD
- **Daten:** Postgres, MongoDB, Neo4j, Vektordatenbanken (Qdrant, Pinecone, Azure AI Search), Pandas, Scikit-Learn, PyTorch
- **Arbeitsweise:** KI-gestützte Entwicklung mit Claude Code, Beratung von Fachbereichen, Agile

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Nebenfach Informatik) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)