# CHANDU PRASAD BHAIRAPU



**AI Engineer**

**bhairapuchanduprasad@gmail.com** **(+49) 15560194877** **Erlangen • Blaue Karte EU** **linkedin** **github**

## PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf KI-gestützte Anwendungen mit Large Language Models (LLMs) und RAG über den gesamten Stack, von Python-Backends, APIs und Datenbanken bis zu React-Frontends, Containern und CI/CD. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft.

## BERUFSERFAHRUNG

### Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

**Kniit GmbH**

Nov. 2025 – heute  Muldestausee

- Alleinverantwortliche Entwicklung und Weiterentwicklung einer KI-gestützten Anwendung zur Wissensextraktion über den gesamten Stack, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indexierung; direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten.
- Multi-Agenten-System mit LangGraph für regulatorische und technische Dokumente; Fehlerursachen systematisch gegen eine Ground Truth aus SAP-Systemen analysiert und behoben, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Deterministische (codebasierte) Pipeline für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null gesenkt, Genauigkeit annähernd 100 %.
- MCP-Server (Model Context Protocol) als Schnittstelle zum Knowledge Graph mit Latenzen im Millisekundenbereich, angebunden an Claude Code.
- Expert Interface: Web-App mit React-Frontend und Python-Microservices-Backend auf Azure, in der Fachanwender Änderungen am Knowledge Graph prüfen und freigeben; Betrieb mit Docker und Kubernetes.
- **Tech-Stack: Python, React, FastAPI, Neo4j, MongoDB, Postgres, LangGraph, LangChain, LiteLLM, RAG, GraphRAG, MCP, Docker, Kubernetes, Azure**

---

### GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

**Covestro Deutschland AG**

Dez. 2024 – Apr. 2025  Leverkusen

- Entwicklung und Deployment einer agentischen KI-Anwendung mit LangGraph (Vektordatenbank-Suche, LLM-Inferenz, Zusammenfassung) mit Python/FastAPI-Backend und React-Frontend; API-Tests mit Postman.
- Containerisierung mit Docker, Deployment auf AWS mit CDK bis zum Go-Live, Versionierung und CI/CD-Pipelines in GitLab.
- Anforderungen mit Business-Stakeholdern erhoben, Nutzen agentischer KI bewertet und in ein Lösungskonzept übersetzt.
- **Tech-Stack: Python, FastAPI, React, LangGraph, LangChain, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD, Postman**

---

### GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

**Covestro Deutschland AG**

Mai 2024 – Nov. 2024  Leverkusen

- Automatisierte Evaluierung von Antwortqualität und Retrieval des RAG-Systems PrismaChat mit RAGAS und PytrecEval gegen eine von Chemikern erstellte Ground Truth, auf serverloser AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks; Konzeption von RAG-Pipelines (Chunking, Vektordatenbanken, Indexierung).
- **Tech-Stack: Python, RAGAS, PytrecEval, LangChain, Hugging Face Transformers, AWS (Lambda, SQS, DynamoDB, CDK), Azure AI Search**

---

### Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

**Covestro Deutschland AG**

Nov. 2023 – Apr. 2024 | Leverkusen

- Training und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Syntheseergebnissen aus Zeitreihen-Prozessdaten; Streamlit-Dashboard für Chemiker.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, Streamlit**

---

### Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

**Cognizant Technology Solutions**

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von Zeitreihenmodellen (ARIMA, SARIMA, XGBoost, FB Prophet, LSTM) zur Lastprognose für Elektrofahrzeuge; LSTM mit 96 % Testgenauigkeit.

## PROJEKTE

**Projekt: Autohaus Service Agent | Python | FastAPI | LangGraph | Qdrant | Postgres**

- RAG-Backend für einen Werkstatt-Assistenten: Ingestion synthetischer Handbücher und Preislisten in Qdrant, Dense- und Keyword-Retrieval mit Kontextbudget, LangGraph-Agent mit in Postgres persistiertem Zustand, Retries mit Backoff und Übergabe an einen Menschen bei Fehlern.
- Logging von Latenz, Token-Verbrauch und Kosten pro Anfrage mit Metrik-Endpunkt für Monitoring und Observability; RAGAS-Evaluierung und pytest-Tests in der CI/CD-Pipeline, Drift-Check gegen die letzte Baseline; docker-compose.

## TECHNISCHE KENNTNISSE

- **Backend & Frontend:** Python, FastAPI, Python-Microservices, REST-APIs und Schnittstellen, SQL, React, API-Tests (Postman)
- **LLMs & RAG:** Retrieval-Augmented Generation, GraphRAG, LangGraph, LangChain, LiteLLM, MCP, Prompt Engineering, RAGAS, Hugging Face Transformers
- **Datenbanken:** Postgres, MongoDB, Neo4j, DynamoDB, Vektordatenbanken (Qdrant, Pinecone, Azure AI Search)
- **Cloud, Container & CI/CD:** Docker, Kubernetes, Azure, AWS (EC2, Lambda, SQS, S3, CDK), Git, GitLab CI/CD
- **Arbeitsweise:** Automatisierung von Tests, Evaluierung und Deployment über CI/CD, KI-gestützte Entwicklung mit Claude Code, Abstimmung mit Fachexperten und Stakeholdern, Agile

## AUSBILDUNG

**Master of Science, Künstliche Intelligenz** — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

**Bachelor of Technology, Maschinenbau (Nebenfach Informatik)** — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien

## PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

## SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)