CHANDU PRASAD BHAIRAPU



GenAI Developer

bhairapuchanduprasad@gmail.com (+49) 15560194877 München • Blaue Karte EU linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf LLM-Anwendungen mit Generative AI, von Prompt Engineering und der Anbindung externer Daten bis zur systematischen Evaluation von Qualität und Kosten. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, ergänzt durch Data-Science-Erfahrung.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute | Muldestausee

- Alleinverantwortliche Entwicklung einer LLM-Anwendung zur Wissensextraktion von der Idee bis zur Übergabe: Datenaufnahme, Chunking, Prompt Engineering, Indexierung; direkt dem CTO unterstellt, Anforderungen gemeinsam mit SAP-Fachexperten erarbeitet.
- Mehrstufiger Multi-Agenten-Ablauf mit LangGraph (Entitätsextraktion, Beziehungsanalyse, Konsolidierung, Reflection) für regulatorische und technische Dokumente; systematische Evaluation gegen eine Ground Truth aus SAP-Systemen, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Technische Entscheidung nach Kosten und Qualität: deterministische (codebasierte) Pipeline statt LLM für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null gesenkt, Genauigkeit annähernd 100 %.
- Systemintegration: MCP-Server (Model Context Protocol) für Abfragen auf dem Knowledge Graph mit Latenzen im Millisekundenbereich; Web-App (React, Python-Microservices) auf Azure, in der Fachexperten Änderungen prüfen und freigeben.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, MCP, RAG, GraphRAG, Neo4j, MongoDB, Postgres, FastAPI, Docker, Kubernetes, Azure**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 | Leverkusen

- Analyse der Entscheidungsprozesse von Fachbereichen, Beratung zum Einsatz agentischer KI und Übersetzung der Anforderungen in ein Lösungskonzept.
- Entwicklung und Deployment einer LLM-Anwendung mit LangGraph, die Anfragen an Vektordatenbank-Suche, LLM-Inferenz oder Zusammenfassung weiterleitet; Python/FastAPI-Backend, React-Frontend, API-Tests mit Postman, Docker, AWS (CDK), GitLab CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD, React**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Wiederholbare, automatisierte Evaluation von Antwortqualität und Retrieval des RAG-Systems PrismaChat mit RAGAS und PytrecEval gegen eine von Chemikern erstellte Ground Truth, auf AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK.
- Systematischer Vergleich mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks interner Chemiedaten; Konzeption von RAG-Pipelines und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, RAGAS, PytrecEval, LangChain, Hugging Face Transformers, PyTorch, AWS, Azure AI Search**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Training und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Syntheseergebnissen aus Zeitreihen-Prozessdaten, mit Feature Engineering (Lag-Features, gleitende Fenster); Streamlit-Dashboard, in dem Chemiker Parameteränderungen vor einer Charge simulieren.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von Zeitreihenmodellen (ARIMA, SARIMA, XGBoost, FB Prophet, LSTM) zur Lastprognose für Elektrofahrzeuge; LSTM mit 96 % Testgenauigkeit.

PROJEKTE

Projekt: Agent Eval Harness | Python | LangGraph | LiteLLM | OpenTelemetry | GitHub Actions

- Evaluations- und Test-Harness für einen Tool-Calling-Agenten über eine gemockte API: Golden Dataset mit Regressions-, Grenz- und adversarialen Fällen, zuerst deterministische Prüfungen (JSON-Schema, Tool-Call-Payloads), danach LLM-as-a-Judge, Pass-Raten über mehrere Läufe mit Konfidenzintervallen.
- Tests für Prompt Injection und fehlerhafte Eingaben, Tracing mit OpenTelemetry und Arize Phoenix für das Monitoring, Ausführung als Quality Gate in GitHub Actions.

Projekt: Meme Generation using LLMs | Open Llama 3B | QLoRA Fine-Tuning

- Fine-Tuning eines Open-Llama-3B-Modells mit QLoRA zur Generierung von Antworten auf Meme-Prompts.

TECHNISCHE KENNTNISSE

- **Generative AI & LLMs:** Large Language Models, Prompt Engineering, RAG, GraphRAG, Agenten (LangGraph, LangChain), MCP, LiteLLM, QLoRA-Fine-Tuning, Hugging Face Transformers
- **Evaluation:** Ground-Truth-Evaluation (Precision/Recall), RAGAS, PytrecEval, Modellvergleich (Embedding-Modelle), Kosten-/Qualitäts-Abwägung
- **Programmierung & APIs:** Python, SQL, FastAPI, REST-APIs, Python-Microservices, Git, React (Grundkenntnisse)
- **Cloud & Datenbanken:** Docker, Kubernetes, Azure, AWS (Lambda, SQS, DynamoDB, S3, CDK), GitLab CI/CD, Postgres, MongoDB, Neo4j, Vektordatenbanken
- **Data Science:** Scikit-Learn, XGBoost, PyTorch, TensorFlow/Keras, Pandas, NumPy, Zeitreihenmodelle

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Nebenfach Informatik) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)