CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Deutschland • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf agentische LLM-Systeme, von Agent-Architektur, RAG und Vektor-Datenbanken über Evals gegen Ground Truth bis zum Deployment, mit Backend und Frontend aus einer Hand. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, in enger Abstimmung mit Fachexperten und Anwendern.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Entwicklung und Optimierung einer Agent-Architektur mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Evals gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Aufbau einer deterministischen (codebasierten) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- Alleinverantwortliche End-to-End-Entwicklung der Datenpipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Backend aus Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen prüfen und freigeben.
- Konzeption und Umsetzung eines MCP-Servers (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich bereitstellt, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Einsatz von Coding Agents (Claude Code, eigene Skills, agentische Coding-Workflows) für schnelle, wartbare Lösungen nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, RAG, GraphRAG, Vector Search, Postgres, Neo4j, MongoDB, FastAPI, React, Docker, Kubernetes, Azure**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Aufnahme der Entscheidungsabläufe mit Fachanwendern und Beratung zum Einsatz agentischer KI; Konzeption und Deployment einer LangGraph-Agent-Anwendung, die Anfragen auf Vektordatenbank-Abfragen, allgemeine Inferenz und Zusammenfassungen verteilt.
- Entwicklung von Frontend (React) und Backend (Python, FastAPI) mit API-Design für die Agent-Anwendung; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in GitLab mit CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Docker, AWS (CDK, Lambda), GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Systematisches Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks interner Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierungsmethoden und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, PyTorch, Hugging Face Transformers, LangChain, RAGAS, Vektordatenbanken, AWS CDK**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Training und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Time-Series-Prozessdaten; Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Time-Series-Analyse für Elektrofahrzeuge.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Clinical Info Assistant | TypeScript | Next.js | Vercel AI SDK | pgVector | promptfoo

- Q&A-Web-App über öffentliche Arzneimittel-Fachinformationen in Full-Stack-TypeScript (Next.js, Drizzle, Zod) mit Vercel AI SDK, LiteLLM und pgVector; Grounding-Guardrail gegen unbelegte Antworten, promptfoo-Evals zu Qualität, Kosten und Latenz in CI und Traces in Arize Phoenix.

TECHNISCHE KENNTNISSE

- **AI Engineering:** LangGraph, LangChain, LiteLLM, RAG, GraphRAG, Prompt Engineering, MCP, Evals (Ground Truth, RAGAS, PytrecEval), QLoRA-Fine-Tuning
- **Backend & Daten:** Python, FastAPI, API-Design, Python-Microservices, SQL, Postgres, MongoDB, Neo4j, Vektor-Datenbanken (Qdrant, Pinecone, Azure AI Search)
- **Frontend & Betrieb:** React, Streamlit, Docker, Kubernetes, Azure, AWS (CDK, Lambda), Git, GitLab CI/CD, Testing mit Postman, Claude Code
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien