CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Bremen • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf agentische Systeme, von Multi-Agenten-Architekturen, RAG und MCP bis zu Evaluation und Betrieb von KI-Anwendungen auf Azure und AWS. Zuletzt alleiniger Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit fundierter Basis in Machine Learning und Python.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung einer Multi-Agenten-Architektur mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) zur Dokumentenintelligenz auf komplexen regulatorischen und technischen Dokumenten; Evaluation gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Alleinverantwortlich für die End-to-End-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indexierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Zusammenarbeit mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Entwicklung einer deterministischen (codebasierten) Extraktionspipeline für einen zweiten, volumenstarken Datenstrom; Token-Kostenkontrolle: prognostiziertes LLM-Budget von 200.000 $ auf nahezu null gesenkt, bei einer Genauigkeit nahe 100 %.
- Implementierung eines MCP-Service (Model Context Protocol), der den Knowledge Graph als Tool für Abfragen in Millisekunden bereitstellt, direkt in Claude Code für agentische Entwicklungsworkflows eingebunden.
- Entwicklung des Expert Interface, einer Web-App (React-Frontend, Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graph prüfen und freigeben (Human-in-the-Loop).
- Konsequent agentisches Arbeiten im Entwicklungsalltag: Claude Code, eigene Skills und Coding-Agenten in agentischen Entwicklungsworkflows, für schnelle, qualitativ hochwertige Entwicklung nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, MCP, RAG, GraphRAG, Azure, Kubernetes, Docker, FastAPI, Neo4j**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Konzeption und Deployment einer agentischen KI-Anwendung mit LangGraph für die Entscheidungsabläufe der Fachbereiche; Routing der Anfragen an Vektordatenbank-Suche, LLM-Inferenz oder Zusammenfassung.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK (Infrastructure-as-Code) nach Clean-Code-Prinzipien; Versionierung in GitLab mit CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Docker, AWS CDK, Lambda, GitLab CI/CD, Postman**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval des RAG-Systems mit RAGAS und PytrecEval, Vergleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken (u. a. Azure AI Search), Indexierung und Fine-Tuning von Modellen für das Retrieval.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Chunks interner Chemiedaten.

- Aufbau der AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die Evaluation des RAG-Systems PrismaChat.
- **Tech-Stack: Python, Azure AI Search, LangChain, Hugging Face Transformers, RAGAS, PytrecEval, PyTorch, AWS CDK, Docker**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Syntheseergebnissen (z. B. Viskosität, Reaktionsverlauf) aus Zeitreihen-Prozessdaten; Vergleich baumbasierter und Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit) für die Baummodelle; Rohsequenzen direkt für das LSTM.
- Benchmarking gegen empirische Kurvenanpassung; frühere Erkennung von Chargen, die von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen vor physischen Versuchen simulieren und Vorhersagen sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, SciPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-, FB-Prophet- und LSTM-Modellen zur Lastprognose für E-Autos.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Leistung auf ungesehenen Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Azure AI Agent Starter-Kit | Azure OpenAI | Azure AI Search | Terraform

- Referenzarchitektur für einen Wissensassistenten mit RAG und einem zweiten Agenten über einen eigenen MCP-Server: Terraform und Azure-DevOps-Pipelines stellen Azure OpenAI, Azure AI Search und Key Vault bereit (Entra ID, Managed Identity); Prompt-Versionierung, Token-Kosten-Logging, Application Insights und RAGAS-Evaluation als Quality-Gate.

TECHNISCHE KENNTNISSE

- **Agentische Systeme & GenAI:** Multi-Agenten-Systeme (LangGraph, LangChain), MCP, RAG, GraphRAG, Dokumentenintelligenz, Prompt Engineering, LiteLLM, Evaluation (RAGAS, PytrecEval), QLoRA
- **Cloud & LLMOps:** Microsoft Azure, Azure AI Search, AWS, Infrastructure-as-Code (AWS CDK), Docker, Kubernetes, GitLab CI/CD
- **Software & Daten:** Python, FastAPI, Python-Microservices, React, REST-APIs, Git, SQL, Postgres, MongoDB, Neo4j, Vektordatenbanken, PyTorch, Scikit-Learn
- **Arbeitsweise:** Beratung von Fachbereichen, Zusammenarbeit mit Fachexperten, Claude Code, Agile

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Nebenfach Informatik) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien

PUBLIKATION & ZERTIFIKATE

- **[1]** Navigating the Future: An approach of Autonomous Indoor Vehicles
- Udemy - LLMs Mastery : Transformers & Generative AI

SPRACHEN

Deutsch (B1) | Englisch (verhandlungssicher) | Hindi (fließend) | Telugu (Muttersprache)