# CHANDU PRASAD BHAIRAPU



## AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Köln • Blaue Karte EU linkedin
github

## PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf Generative AI mit LLMs, RAG und AI Agents sowie auf Training und Evaluierung von Machine-Learning-Modellen. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit fundierter Basis in Machine Learning, Deep Learning und Python-Entwicklung in Konzern und Start-up.

## BERUFSERFAHRUNG

### Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

**Kniit GmbH**

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung von AI Agents und Multi-Agent-Workflows mit LangGraph auf Basis von Large Language Models (LLMs) (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Alleinverantwortliche End-to-End-Entwicklung der LLM-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Backend aus Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Kostenoptimierung durch eine deterministische (codebasierte) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen für Retrieval mit Latenzen im Millisekundenbereich bereitstellt, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Entwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LLMs, RAG, LangGraph, LangChain, LiteLLM, GraphRAG, MCP, FastAPI, React, Neo4j, MongoDB, PostgreSQL, Docker, Kubernetes, Azure**

---

### GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

**Covestro Deutschland AG**

Dez. 2024 – Apr. 2025 Leverkusen

- Aufnahme der Entscheidungsabläufe gemeinsam mit Fachanwendern, Beratung, wo agentische KI sie unterstützen kann (KI-Anwendungsfälle), und Übersetzung der Anforderungen in den Lösungsansatz; Konzeption und Deployment einer KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, allgemeine LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in GitLab mit CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Postman, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD**

---

### GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

**Covestro Deutschland AG**

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierungsmethoden und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, PyTorch, Hugging Face Transformers, LangChain, RAGAS, PytrecEval, AWS CDK**

---

### Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

**Covestro Deutschland AG**

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung eigener ML-Modelle (Random Forest, XGBoost, LSTM) auf domänenspezifischen Zeitreihen-Prozessdaten zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt); Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, SciPy, Streamlit**

---

### Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

**Cognizant Technology Solutions**

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

## PROJEKTE

**Projekt: LLM Gateway | Python | FastAPI | LLM-APIs | Monitoring | CI**

- Anbieterunabhängige API-Schicht über mehrere LLM-Anbieter mit Token-Budgets, Timeouts, Retries und Fallbacks zwischen Anbietern; Monitoring von Latenz, Token-Verbrauch und Kosten je Anfrage, Tests und Evaluierung in CI.

## TECHNISCHE KENNTNISSE

- **Generative AI:** Large Language Models (LLMs), RAG, AI Agents, Prompt Engineering, LangGraph, LangChain, LiteLLM, GraphRAG, MCP, Hugging Face Transformers, QLoRA-Fine-Tuning
- **Machine Learning & Deep Learning:** PyTorch, TensorFlow/Keras, scikit-learn, XGBoost, Zeitreihenanalyse, Modelltraining und -evaluierung, RAG-Evaluation (RAGAS, PytrecEval), Pandas, NumPy
- **Programmierung & Daten:** Python, FastAPI, REST-APIs, Postman, React (Grundkenntnisse), SQL, PostgreSQL, MongoDB, Neo4j, Vektordatenbanken (Qdrant, Pinecone, Azure AI Search)
- **Cloud & MLOps:** Azure, AWS (CDK, Lambda, SQS, DynamoDB, EC2), Docker, Kubernetes, Git, GitLab CI/CD, Claude Code
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

## AUSBILDUNG

**Master of Science, Künstliche Intelligenz** — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

**Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering)** — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien