CHANDU PRASAD BHAIRAPU



AI Developer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Osnabrück • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf generative KI und Large Language Models, von Prompts und Workflows über LLM-Anwendungen mit RAG bis zu belastbaren Prototypen, die gemeinsam mit Fachbereichen entstehen und auf AWS und Azure bereitgestellt werden. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, gestützt auf Beratungserfahrung mit Fachanwendern.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph auf Basis von Large Language Models (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Alleinverantwortliche End-to-End-Entwicklung der LLM-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt-Entwicklung bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Backend aus Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Aufbau einer deterministischen (codebasierten) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen für Retrieval mit Latenzen im Millisekundenbereich bereitstellt, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Schnelle Umsetzung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LLMs, LangGraph, LangChain, LiteLLM, RAG, GraphRAG, MCP, FastAPI, React, Neo4j, MongoDB, PostgreSQL, Docker, Kubernetes, Azure**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Aufnahme der Entscheidungsabläufe gemeinsam mit Fachanwendern, Beratung, wo agentische KI sie unterstützen kann (KI-Anwendungsfälle), und Übersetzung der Anforderungen in den Lösungsansatz; Konzeption und Deployment einer KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, allgemeine LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in GitLab mit CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Postman, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierungsmethoden und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, PyTorch, Hugging Face Transformers, LangChain, RAGAS, PytrecEval, AWS CDK**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung eigener ML-Modelle (Random Forest, XGBoost, LSTM) auf domänenspezifischen Zeitreihen-Prozessdaten zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt); Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, SciPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Interner GPT-Wissensassistent | Python | LlamaIndex | Open-Source-LLM | FastAPI | MCP

- RAG-Assistent über interne Prozessdokumente mit einem lokal betriebenen Open-Source-LLM, datenschutzkonform, da keine Daten das Haus verlassen; Antworten nennen ihre Quellen, Bereitstellung über eine FastAPI-REST-API und einen MCP-Server; pytest und RAGAS-Evaluationsset in GitLab CI/CD, Request-Logging für das Monitoring.

TECHNISCHE KENNTNISSE

- **Generative KI & LLMs:** Large Language Models, Prompt Engineering, LangGraph (Workflows, Multi-Agent), LangChain, LiteLLM, RAG, GraphRAG, MCP, Hugging Face Transformers, QLoRA-Fine-Tuning, RAGAS-Evaluation
- **Entwicklung:** Python, FastAPI, REST-APIs, Python-Microservices, Postman, React (Grundkenntnisse)
- **Data Science & Machine Learning:** SQL, PostgreSQL, MongoDB, Neo4j, Vektor-Datenbanken (Qdrant, Pinecone, Azure AI Search), Scikit-Learn, XGBoost, PyTorch, TensorFlow/Keras, Pandas, Streamlit
- **Betrieb & Cloud:** Git, GitLab CI/CD, Docker, Kubernetes, Azure, AWS (CDK, Lambda, SQS, DynamoDB), Claude Code
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien