CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Dortmund • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf Python-basierte Backend-Services mit REST-APIs und die produktive Integration von Large Language Models, ergänzt um eigene Machine-Learning-Modelle auf domänenspezifischen Daten. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, gestützt auf Erfahrung mit Datenpipelines, Containerisierung und Cloud-Deployments auf AWS und Azure.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche End-to-End-Entwicklung der Datenpipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Backend aus Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Konzeption und Optimierung von Multi-Agent-Extraktionsalgorithmen mit LangGraph auf Basis von LLM-APIs (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Evaluation gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Aufbau einer deterministischen (codebasierten) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen für Retrieval mit Latenzen im Millisekundenbereich bereitstellt, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Agentic Development mit Claude Code, eigenen Skills und agentischen Coding-Workflows für schnelle, wartbare Lösungen nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, PostgreSQL, MongoDB, Neo4j, FastAPI, RAG, GraphRAG, MCP, Docker, Kubernetes, Azure, React**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Entwicklung eines Python-Backends mit REST-APIs auf Basis von FastAPI und eines React-Frontends; API-Tests mit Postman.
- Aufnahme der Entscheidungsabläufe mit Fachanwendern; Konzeption und Deployment einer KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, allgemeine LLM-Inferenz und Zusammenfassungen verteilt.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung mit Git in GitLab mit CI/CD.
- **Tech-Stack: Python, FastAPI, LangGraph, LangChain, Docker, AWS (CDK, EC2, Lambda), Git, GitLab CI/CD, Postman, React**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Systematisches Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks interner Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierungsmethoden und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, PyTorch, Hugging Face Transformers, LangChain, RAGAS, PytrecEval, AWS CDK**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung eigener ML-Modelle (Random Forest, XGBoost, LSTM) auf domänenspezifischen Zeitreihen-Prozessdaten zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt); Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards als KI-gestützte Analysefunktion, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, SciPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Canteen Menu Insights | Python | FastAPI | XGBoost | LLM-API | Firestore | Google Cloud Run

- Python-Backend mit REST-APIs und Datenmodell in Firestore über synthetischen Kantinen-Speiseplänen, eigenes XGBoost-Modell zur Nachfrageprognose je Gericht und eine LLM-gestützte Reporting-Funktion mit Prüfung gegen die Kennzahlen; pytest in GitHub Actions (CI/CD), Docker-Deployment auf Google Cloud Run.

TECHNISCHE KENNTNISSE

- **Backend & Data Engineering:** Python, FastAPI, REST-APIs, Datenmodellierung, SQL, PostgreSQL, MongoDB, Neo4j, Vektor-Datenbanken (Qdrant, Pinecone, Azure AI Search)
- **Applied AI & generative KI:** Large Language Models, LLM-APIs, LiteLLM, LangGraph, LangChain, RAG, GraphRAG, Prompt Engineering, MCP, RAGAS-Evaluation
- **Machine Learning:** Scikit-Learn, XGBoost, PyTorch, TensorFlow/Keras, Hugging Face, Zeitreihenanalyse, Pandas, NumPy, Streamlit
- **Betrieb & Cloud:** Git, GitLab CI/CD, Docker, Kubernetes, AWS (CDK, Lambda, SQS, DynamoDB), Azure, Claude Code
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien