CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877
Neustadt an der Weinstraße • Blaue Karte EU linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf LLM-basierte AI-Agents und agentische Systeme, von LangGraph-Workflows über die Anbindung von Systemen per API und Model Context Protocol bis zum Betrieb in Docker und Kubernetes. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit solider Basis in Python und Automatisierung.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute | Muldestausee

- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) zur Wissensextraktion aus komplexen regulatorischen und technischen Dokumenten; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich abfragbar macht, direkt integriert in Claude Code für agentische Workflows.
- Entwicklung einer deterministischen (codebasierten) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt, Extraktionsgenauigkeit an 100 % herangeführt.
- Alleinverantwortliche End-to-End-Entwicklung der LLM-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Entwicklung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- KI-gestützte Softwareentwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, MCP, LiteLLM, Docker, Kubernetes, Azure, Git, Claude Code, FastAPI, React, PostgreSQL, MongoDB, Neo4j, RAG, GraphRAG**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 | Leverkusen

- Konzeption und Deployment einer agentischen KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt, abgeleitet aus Entscheidungsabläufen der Fachbereiche.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung mit Git (GitLab) und CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierung und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, AWS CDK, Docker**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten; Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines interaktiven Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Pandas, NumPy, SciPy, Scikit-Learn, XGBoost, TensorFlow/Keras, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenanalyse der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Self-Hosted LLM Inference Platform | vLLM | llama.cpp | Open WebUI | LiteLLM

- Lokal betriebene Open-Source-LLMs (Qwen, Gemma) mit vLLM und llama.cpp hinter einem LiteLLM-Proxy, Open WebUI als Oberfläche; Python-Skripte für Benchmarking und Smoke-Tests neuer Modellversionen.

TECHNISCHE KENNTNISSE

- **LLMs & AI-Agents:** Large Language Models (LLM-Integration), Context Management, LangGraph, LangChain, LiteLLM, Model Context Protocol (MCP), Context Management, RAG, GraphRAG, QLoRA-Fine-Tuning, RAG-Evaluation, Claude Code
- **Entwicklung & Automatisierung:** Python (Skripting, Microservices), FastAPI, REST-APIs, Git, GitLab CI/CD, SQL, PostgreSQL, MongoDB, Neo4j
- **Infrastruktur:** Docker, Kubernetes, Azure, AWS (Lambda, SQS, DynamoDB, S3, EC2, CDK)
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien