CHANDU PRASAD BHAIRAPU



GenAI Developer

bhairapuchanduprasad@gmail.com (+49) 15560194877 München • Blaue Karte EU linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf GenAI-Anwendungen mit RAG-Architekturen und agentischen Workflows, von Fine-Tuning und Evaluation bis zur Full-Stack-Integration mit FastAPI-Backends und React-Frontends und zum Deployment mit Docker und Kubernetes. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, gestützt auf eine solide Basis in Machine Learning und Deep Learning.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung agentischer Workflows mit LangGraph auf Basis von LLMs (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Alleinverantwortliche End-to-End-Entwicklung der GenAI-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien) für GraphRAG; direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich für KI-Agenten abfragbar macht, direkt integriert in Claude Code.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Backend aus Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen prüfen und freigeben.
- Kostenoptimierung durch eine deterministische (codebasierte) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- KI-gestützte Softwareentwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, RAG, GraphRAG, MCP, Microservices, FastAPI, React, Docker, Kubernetes, Azure, Neo4j**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Aufnahme der Entscheidungsabläufe gemeinsam mit Fachanwendern, Beratung zu passenden Use Cases und Übersetzung der Anforderungen in eine technische Lösung: KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines Python-Backends mit FastAPI (REST-APIs, automatisch generierte OpenAPI-Dokumentation) und eines React-Frontends; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in Git (GitLab) mit CI/CD.
- **Tech-Stack: Python, FastAPI, LangGraph, LangChain, React, Docker, AWS CDK, GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Konzeption von RAG-Architekturen mit Fokus auf Chunking-Strategien, Vector Databases, Indizierung und Fine-Tuning von Transformer-Modellen für das Retrieval.
- Benchmarking mehrsprachiger Embeddings-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- **Tech-Stack: Python, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, AWS CDK**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich klassischer Machine-Learning- und Deep-Learning-Modelle (Random Forest, XGBoost, LSTM) zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten; Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Pandas, NumPy, Scikit-Learn, XGBoost, TensorFlow/Keras, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: GenAI-Service für Bestandsanwendungen | LangGraph | Azure OpenAI | Spring Boot | Angular

- GenAI-Service mit FastAPI und LangGraph (RAG mit Embeddings und Vektordatenbank, Azure OpenAI, Guardrails mit Grounding-Check und RAGAS-Evaluation), angebunden über eine OpenAPI/Swagger-Spezifikation an ein Spring-Boot-Backend und eine Angular-Oberfläche (TypeScript); Docker und Kubernetes.

TECHNISCHE KENNTNISSE

- **GenAI:** LLMs, RAG, GraphRAG, agentische Workflows (LangGraph), LangChain, LiteLLM, MCP, Prompt Engineering, Embeddings, Fine-Tuning (QLoRA), Hugging Face Transformers, RAGAS
- **Vector Databases:** Qdrant, Pinecone, Azure AI Search; Datenbanken: SQL, PostgreSQL, MongoDB, Neo4j
- **ML & Deep Learning:** PyTorch, TensorFlow, Scikit-Learn, XGBoost, Pandas
- **Entwicklung & Betrieb:** Python, FastAPI, REST-APIs, Microservices, React (Basis), Streamlit, Docker, Kubernetes, Azure, AWS (CDK, Lambda), Git, GitLab CI/CD
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien