CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 München • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf die Integration und Bereitstellung von LLM-Diensten, von LiteLLM und Containern auf Kubernetes bis zu KI-gestützten Entwicklungswerkzeugen wie Claude Code. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit solider Basis in Python, Softwareentwicklung und Fehleranalyse.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) zur Wissensextraktion aus komplexen regulatorischen und technischen Dokumenten; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- KI-gestützte Softwareentwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- Alleinverantwortliche End-to-End-Entwicklung der LLM-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Entwicklung einer deterministischen (codebasierten) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt, Extraktionsgenauigkeit an 100 % herangeführt.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich abfragbar macht, direkt integriert in Claude Code für agentische Workflows.
- Entwicklung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (React-Frontend, Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- **Tech-Stack: Python, LiteLLM, Kubernetes, Docker, Azure, Claude Code, MCP, LangGraph, LangChain, RAG, GraphRAG, FastAPI, React, PostgreSQL, MongoDB, Neo4j**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Konzeption und Deployment einer agentischen KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt, abgeleitet aus Entscheidungsabläufen der Fachbereiche.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung mit Git (GitLab) und CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, React, Docker, AWS (CDK, EC2, Lambda), GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierung und Fine-Tuning von Modellen für das Retrieval.
- **Tech-Stack: Python, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, AWS CDK, Docker**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten; Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines interaktiven Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Pandas, NumPy, SciPy, Scikit-Learn, XGBoost, TensorFlow/Keras, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenanalyse der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Self-Hosted LLM Inference Platform | vLLM | LiteLLM | Kubernetes | Python

- On-Premises-Setup auf einem lokalen Kubernetes-Cluster: Open-Source-LLMs als Inferenzdienste mit vLLM bereitgestellt, LiteLLM-Proxy als einheitliche OpenAI-kompatible Schnittstelle mit Schlüsseln pro Team, angebunden an VS Code und Cursor; Python-Skripte für Smoke-Tests neuer Versionen vor dem Rollout und ein Troubleshooting-Runbook mit Logs und Metriken.

TECHNISCHE KENNTNISSE

- **KI-Plattformen & DevOps:** LiteLLM, Kubernetes, Docker, Claude Code (agentisches Coding), MCP, Git, GitLab CI/CD, Azure, AWS (Lambda, SQS, DynamoDB, S3, EC2, CDK), Fehleranalyse und Troubleshooting
- **Generative KI & LLMs:** LLM-Orchestrierung mit LangGraph und LangChain, LLM-Inferenz, RAG, GraphRAG, Prompt Engineering, RAG-Evaluation (RAGAS, PytrecEval), QLoRA-Fine-Tuning
- **Softwareentwicklung:** Python (Skripting, Microservices), FastAPI, REST-APIs, Postman, SQL, PostgreSQL, MongoDB, Neo4j, Vektordatenbanken, React (Grundkenntnisse)
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien