CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Frankfurt am Main • Blaue Karte EU
linkedin github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf Python-Backends und REST-APIs mit integrierten LLM- und RAG-Komponenten, von Datenpipelines über Embeddings und Vector Search bis zum Cloud-Deployment auf Microsoft Azure und AWS. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit solider Basis in Machine Learning und Datenanalyse.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche End-to-End-Entwicklung der Daten- und LLM-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Kostenoptimierung durch eine deterministische (codebasierte) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) zur strukturierten Extraktion aus regulatorischen und technischen Dokumenten; Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (Backend aus Python-Microservices, React-Frontend) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich abfragbar macht, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- KI-gestützte Entwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, FastAPI, PostgreSQL, RAG, Vector Search, Azure, Docker, Kubernetes, LangGraph, LiteLLM, Neo4j, MCP**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Konzeption und Deployment einer KI-Anwendung mit LangGraph nach den Entscheidungsabläufen der Fachanwender, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines Python-Backends mit FastAPI (REST-APIs) und eines React-Frontends; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in Git (GitLab) mit CI/CD.
- **Tech-Stack: Python, FastAPI, LangGraph, LangChain, React, Docker, AWS CDK, GitLab CI/CD**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierung und Fine-Tuning von Modellen für das Retrieval.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- **Tech-Stack: Python, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, AWS CDK**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten; Bewertung baumbasierter vs. Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen simulieren und die Vorhersage vor dem Ansetzen einer Charge sehen.
- **Tech-Stack: Python, Pandas, NumPy, Scikit-Learn, XGBoost, TensorFlow/Keras, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Leasing-Dokumentenextraktion | Python | FastAPI | Azure OpenAI | PostgreSQL | Terraform

- REST-API mit FastAPI, Pydantic und SQLAlchemy, die synthetische Leasing-Dokumente per OCR einliest, Felder mit Azure OpenAI Structured Outputs extrahiert und über Embeddings und Vector Search (pgvector) einem Objektkatalog in PostgreSQL zuordnet; Stammdaten per Batch-Pipeline aus Databricks, pytest in GitHub Actions, Docker auf Azure Container Apps mit Terraform.

TECHNISCHE KENNTNISSE

- **Entwicklung & APIs:** Python, FastAPI, REST-APIs, SQL, PostgreSQL, MongoDB, Neo4j, Git, React (Basis)
- **KI & GenAI:** RAG, Embeddings, Vector Search (Qdrant, Azure AI Search), LangGraph, LangChain, LiteLLM, Claude Code
- **Data Engineering & ML:** Datenpipelines, Pandas, NumPy, Scikit-Learn, XGBoost, PyTorch, TensorFlow
- **Cloud & DevOps:** Microsoft Azure, AWS (CDK, Lambda, SQS, DynamoDB), Docker, Kubernetes, GitLab CI/CD
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien