CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Stuttgart • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf Generative KI und Wissensmanagement, von RAG und agentischen Systemen bis zum Deployment auf Azure und AWS. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit fundierter Basis in Datenanalyse, Machine Learning und Python-Entwicklung in Konzern- und Start-up-Umfeld.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche End-to-End-Entwicklung der Datenpipeline zur Wissensextraktion vom Prototyp bis zum Einsatz, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit Stakeholdern und SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (Backend aus Python-Microservices, React-Frontend) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich abfragbar macht, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Precision/Recall durch systematische Evaluation von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Kostenoptimierung durch eine deterministische (codebasierte) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- KI-gestützte Entwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Azure, Python, Neo4j, MongoDB, PostgreSQL, Docker, Kubernetes, FastAPI, React, LangGraph, LiteLLM, RAG, MCP**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Anforderungen der Fachanwender in technische Lösungsansätze übersetzt; Konzeption und Deployment einer KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines Python-Backends mit FastAPI (REST-APIs) und eines React-Frontends; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker (Container) und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in Git (GitLab) mit CI/CD.
- **Tech-Stack: Python, Docker, GitLab CI/CD, FastAPI, LangGraph, LangChain, React, AWS CDK**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierung und Fine-Tuning von Deep-Learning-Modellen (PyTorch) für das Retrieval.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- **Tech-Stack: Python, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, AWS CDK**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Machine-Learning- und Deep-Learning-Modellen (Random Forest, XGBoost, LSTM) zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Messdaten (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen (Qualitätsprüfung, Predictive Analytics).
- Bereitstellung eines Streamlit-Prototypen für die Prozessoptimierung: Chemiker simulieren Parameteränderungen und sehen die Vorhersage, bevor sie eine Charge ansetzen.
- **Tech-Stack: Python, scikit-learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Azure AI Agent Starter-Kit | Microsoft Foundry | Azure OpenAI | Azure AI Search

- Referenzarchitektur für einen Wissensassistenten mit RAG und einem zweiten Agenten über einen eigenen MCP-Server: Modelle über Microsoft Foundry, Bereitstellung per Terraform und Azure DevOps (Entra ID, Managed Identity); Prompt-Versionierung, Token-Kosten-Logging und RAGAS-Evaluation als Quality-Gate.

TECHNISCHE KENNTNISSE

- **Cloud & Engineering:** Azure, AWS (CDK, Lambda), Docker, Kubernetes, FastAPI, React, Git, GitLab CI/CD, Claude Code
- **KI & Wissensmanagement:** RAG, GraphRAG, Knowledge Graphs, Vektordatenbanken, LangGraph, LangChain, LiteLLM, MCP, Prompt Engineering, QLoRA-Fine-Tuning
- **Daten & Datenbanken:** Python, SQL, PostgreSQL, Neo4j, MongoDB, Pandas, NumPy, Scikit-Learn, Machine Learning
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien