CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Leipzig • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf generative KI und Multi-Agent-Lösungen, von RAG und Orchestrierung bis zum Betrieb auf Azure und AWS. Zuletzt alleiniger Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit Erfahrung in der Beratung von Fachbereichen.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Konzeption und Optimierung einer Multi-Agenten-Architektur mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) zur Dokumentenintelligenz auf komplexen regulatorischen und technischen Dokumenten; Evaluation gegen eine aus SAP-Systemen abgeleitete Ground Truth, Precision/Recall von 33 %/45 % auf 93 %/90 % gesteigert.
- Alleinverantwortlich für die End-to-End-Pipeline zur Wissensextraktion, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indexierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Zusammenarbeit mit SAP-Fachexperten der deutschen Energiewirtschaft.
- Entwicklung einer deterministischen (codebasierten) Extraktionspipeline für einen zweiten, volumenstarken Datenstrom; Token-Kostenkontrolle: prognostiziertes LLM-Budget von 200.000 $ auf nahezu null gesenkt, bei einer Genauigkeit nahe 100 %.
- Implementierung eines MCP-Service (Model Context Protocol), der den Knowledge Graph als Tool für Abfragen in Millisekunden bereitstellt, direkt in Claude Code für agentische Entwicklungsworkflows eingebunden.
- Entwicklung des Expert Interface, einer Web-App (React-Frontend, Python-Microservices) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graph prüfen und freigeben (Human-in-the-Loop).
- Konsequent agentisches Arbeiten im Entwicklungsalltag: Claude Code, eigene Skills und Coding-Agenten in agentischen Entwicklungsworkflows, für schnelle, qualitativ hochwertige Entwicklung nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LangGraph, LangChain, LiteLLM, MCP, RAG, GraphRAG, Azure, Kubernetes, Docker, FastAPI, Neo4j**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Beratung der Fachbereiche zu agentischer KI; Konzeption und Deployment einer Anwendung mit LangGraph (Orchestrierung) für deren Entscheidungsabläufe; Routing der Anfragen an Vektordatenbank-Suche, LLM-Inferenz oder Zusammenfassung.
- Entwicklung eines React-Frontends und eines Python-Backends mit FastAPI; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker und Deployment auf AWS mit CDK (Infrastructure-as-Code) nach Clean-Code-Prinzipien; Versionierung in GitLab mit CI/CD.
- **Tech-Stack: Python, LangGraph, LangChain, FastAPI, REST-APIs, React, Docker, AWS CDK, Lambda, GitLab CI/CD, Postman**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Automatisierte Evaluation von Generierung und Retrieval des RAG-Systems mit RAGAS und PytrecEval, Vergleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken (u. a. Azure AI Search), Indexierung und Fine-Tuning von Modellen für das Retrieval.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Chunks interner Chemiedaten.
- Aufbau der AWS-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die Evaluation des RAG-Systems PrismaChat.
- **Tech-Stack: Python, Azure AI Search, LangChain, Hugging Face Transformers, RAGAS, PytrecEval, PyTorch, AWS CDK, Docker**

Data Scientist (Praktikum) – ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Vergleich von Random-Forest-, XGBoost- und LSTM-Modellen zur Vorhersage von Syntheseergebnissen (z. B. Viskosität, Reaktionsverlauf) aus Zeitreihen-Prozessdaten; Vergleich baumbasierter und Deep-Learning-Ansätze.
- Feature Engineering mit Lag-Features und gleitenden Fenstern aus Sensor-Zeitreihen (Temperatur, Reaktionszeit) für die Baummodelle; Rohsequenzen direkt für das LSTM.
- Benchmarking gegen empirische Kurvenanpassung; frühere Erkennung von Chargen, die von der Zielspezifikation abweichen.
- Bereitstellung eines Streamlit-Dashboards, in dem Chemiker Parameteränderungen vor physischen Versuchen simulieren und Vorhersagen sehen.
- **Tech-Stack: Python, Scikit-Learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, SciPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-, FB-Prophet- und LSTM-Modellen zur Lastprognose für E-Autos.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Leistung auf ungesehenen Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Azure AI Agent Starter-Kit | Microsoft Foundry | Azure OpenAI | Azure AI Search

- Referenzarchitektur für einen Wissensassistenten mit RAG und einem zweiten Agenten über einen eigenen MCP-Server: Modelle über Microsoft Foundry, Bereitstellung per Terraform und Azure DevOps (Entra ID, Managed Identity); Prompt-Versionierung, Token-Kosten-Logging und RAGAS-Evaluation als Quality-Gate.

TECHNISCHE KENNTNISSE

- **Agentische Systeme & GenAI:** Large Language Models, Multi-Agenten-Systeme und Orchestrierung (LangGraph, LangChain), Retrieval Augmented Generation (RAG), Prompt Engineering, MCP, GraphRAG, LiteLLM, Evaluation (RAGAS, PytrecEval), QLoRA
- **Cloud & LLMOps:** Microsoft Azure, Azure AI Search, AWS, Infrastructure-as-Code (AWS CDK), Docker, Kubernetes, GitLab CI/CD
- **Software & Daten:** Python, FastAPI, Python-Microservices, React, REST-APIs, Git, SQL, Postgres, MongoDB, Neo4j, Vektordatenbanken, PyTorch, Scikit-Learn
- **Arbeitsweise:** Beratung von Fachbereichen, Zusammenarbeit mit Fachexperten, Claude Code, Agile
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Nebenfach Informatik) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien