CHANDU PRASAD BHAIRAPU



AI Engineer

bhairapuchanduprasad@gmail.com (+49) 15560194877 Stuttgart • Blaue Karte EU linkedin
github

PROFIL

Master-Absolvent in Künstlicher Intelligenz mit 3 Jahren Berufserfahrung in AI Engineering und Softwareentwicklung. Spezialisiert auf generative und agentische KI, von LLM-Anwendungen, RAG-Pipelines und MCP-Anbindungen über Evaluation bis zum produktiven Betrieb auf Azure und AWS. Zuletzt alleinverantwortlicher Entwickler eines agentischen Systems zur Wissensextraktion für die deutsche Energiewirtschaft, mit fundierter Basis in Full-Stack-Entwicklung mit Python, FastAPI und React sowie in Machine Learning im Konzern- und Start-up-Umfeld.

BERUFSERFAHRUNG

Associate Generative AI Developer - Agentic Indexing Pipeline Engineer for German Energy Sector

Kniit GmbH

Nov. 2025 – heute Muldestausee

- Alleinverantwortliche End-to-End-Entwicklung der Datenpipeline zur Wissensextraktion vom Prototyp bis zum Einsatz, von Datenaufnahme und Chunking über Prompt Engineering bis zur Indizierung (agentische, deterministische und monolithische Strategien); direkt dem CTO unterstellt, enge Abstimmung mit Stakeholdern und SAP-Fachexperten der deutschen Energiewirtschaft.
- Umsetzung von Expert Interface, einer Web-App zur Kuratierung des Knowledge Graphen (Backend aus Python-Microservices, React-Frontend) auf Microsoft Azure, in der Fachexperten Änderungen am Knowledge Graphen prüfen und freigeben.
- Konzeption und Umsetzung eines MCP-Query-Service (Model Context Protocol), der den Knowledge Graphen mit Latenzen im Millisekundenbereich abfragbar macht, direkt integriert in Claude Code für agentische Entwicklungs-Workflows.
- Konzeption und Optimierung von Multi-Agent-Workflows mit LangGraph (parallele Agenten für Entitätsextraktion, Beziehungsanalyse, Konsolidierung und Reflection) für regulatorische und technische Dokumente; Precision/Recall durch systematische Evaluation von 33 %/45 % auf 93 %/90 % gesteigert, gemessen an einer aus SAP-Systemen abgeleiteten Ground Truth.
- Kostenoptimierung durch eine deterministische (codebasierte) Extraktions-Pipeline für einen zweiten, volumenstarken Datenstrom; ein prognostiziertes LLM-Budget von 200.000 $ auf nahezu null laufende Kosten gesenkt und die Extraktionsgenauigkeit nahe an 100 % herangeführt.
- KI-gestützte Entwicklung mit Claude Code, eigenen Skills und agentischen Coding-Workflows nach Clean-Code-Prinzipien.
- **Tech-Stack: Python, LLM-Anwendungen, RAG, Agents, MCP, LangGraph, LiteLLM, Vector Search, FastAPI, React, APIs, Docker, Kubernetes, Azure, Neo4j, MongoDB, PostgreSQL, Git**

GenAI Developer (Praktikum, KI-Beratung) - Development and Deployment of an Agentic AI Workflow

Covestro Deutschland AG

Dez. 2024 – Apr. 2025 Leverkusen

- Anforderungen der Fachanwender in technische Lösungsansätze übersetzt; Konzeption und Deployment einer KI-Anwendung mit LangGraph, die Anfragen auf Vektordatenbank-Abfragen, LLM-Inferenz und Zusammenfassungen verteilt.
- Entwicklung eines Python-Backends mit FastAPI (REST-APIs) und eines React-Frontends; API-Tests mit Postman.
- Containerisierung des gesamten Stacks mit Docker (Container) und Deployment auf AWS mit CDK nach Clean-Code-Prinzipien; Versionierung in Git (GitLab) mit CI/CD.
- **Tech-Stack: Python, LLM-Anwendungen, Agents, RAG, LangGraph, LangChain, Vector-DB, FastAPI, React, APIs, Docker, CI/CD, AWS CDK, Git (GitLab)**

GenAI Developer (Masterarbeit) - Evaluating the Performance of RAG Systems

Covestro Deutschland AG

Mai 2024 – Nov. 2024 | Leverkusen

- Konzeption von RAG-Pipelines mit Fokus auf Chunking-Strategien, Vektordatenbanken, Indizierung und Fine-Tuning von Deep-Learning-Modellen (PyTorch) für das Retrieval.
- Benchmarking mehrsprachiger Embedding-Modelle auf über 1 Mio. Daten-Chunks aus internen Chemiedaten von Covestro.
- Automatisierte Evaluation von Generierung und Retrieval eines RAG-Systems mit RAGAS und PytrecEval; Abgleich der Modellantworten mit einer von Chemikern erstellten Ground Truth.
- Aufbau der AWS-Cloud-Infrastruktur (Lambda, SQS, DynamoDB) mit CDK für die RAG-Evaluation von PrismaChat.
- **Tech-Stack: Python, RAG, Evaluation, Fine-Tuning, Embeddings, Vector-Datenbanken, LangChain, Hugging Face, PyTorch, RAGAS, PytrecEval, Docker, AWS CDK**

Data Scientist (Praktikum) - ML-Based Prediction of Prepolymer Synthesis Outcomes

Covestro Deutschland AG

Nov. 2023 – Apr. 2024 | Leverkusen

- Entwicklung und Vergleich von Machine-Learning- und Deep-Learning-Modellen (Random Forest, XGBoost, LSTM) zur Vorhersage von Prepolymer-Syntheseergebnissen (z. B. Viskosität, Reaktionsfortschritt) aus Zeitreihen-Prozessdaten.
- Feature Engineering mit Lag-Features und gleitenden statistischen Fenstern aus Sensor-Messdaten (Temperatur, Reaktionszeit, Prozessvariablen) für die baumbasierten Modelle, Rohsequenzen direkt für das LSTM.
- Benchmark der Modelle gegen klassische empirische Kurvenanpassung; frühere Erkennung von Chargen, die voraussichtlich von der Zielspezifikation abweichen (Qualitätsprüfung, Predictive Analytics).
- Bereitstellung eines Streamlit-Prototypen für die Prozessoptimierung: Chemiker simulieren Parameteränderungen und sehen die Vorhersage, bevor sie eine Charge ansetzen.
- **Tech-Stack: Python, scikit-learn, XGBoost, TensorFlow/Keras, Pandas, NumPy, Streamlit**

Machine Learning Engineer - Electrical Vehicle Load Forecasting using Time Series Analysis

Cognizant Technology Solutions

Sep. 2021 – März 2022 | Hyderabad, Indien

- Entwicklung von ARIMA-, SARIMA-, XGBoost-Regressor-, FB-Prophet- und LSTM-Modellen zur Zeitreihenprognose der Ladelast von Elektrofahrzeugen.
- LSTM-Modell mit 96 % Testgenauigkeit und guter Generalisierung auf neue Daten.
- **Tech-Stack: Python, Scikit-Learn, TensorFlow**

PROJEKTE

Projekt: Enterprise Knowledge Agent | Python | LangGraph | Qdrant | FastAPI | RAGAS

- LangGraph-Agent, der Fragen über viele synthetische Dokumente (SharePoint-ähnliche Ordnerstruktur) beantwortet, Quellen zitiert und schwache oder widersprüchliche Belege markiert; RAGAS-Prüfungen in der CI.

TECHNISCHE KENNTNISSE

- **Generative & agentische KI:** LLM-Anwendungen, RAG, KI-Agenten, MCP, Context Engineering, Prompt Engineering, LangGraph, LangChain, LiteLLM, GraphRAG, Vektordatenbanken, RAG-Evaluation (RAGAS, PytrecEval), QLoRA-Fine-Tuning
- **Data Science & ML:** Python, scikit-learn, PyTorch, TensorFlow/Keras, XGBoost, Zeitreihenanalyse, Pandas, SQL, Neo4j, MongoDB
- **Entwicklung & Betrieb:** Python, FastAPI, React, REST-APIs, Docker, CI/CD (GitLab), Kubernetes, Git, Claude Code
- **Cloud:** Azure, AWS (CDK, Lambda)
- **Sprachen:** Deutsch (B1), Englisch (verhandlungssicher), Hindi (fließend), Telugu (Muttersprache)

AUSBILDUNG

Master of Science, Künstliche Intelligenz — März 2022 – Apr. 2025
Technische Hochschule Würzburg-Schweinfurt, Würzburg

Bachelor of Technology, Maschinenbau (Minor in Computer Science & Engineering) — Aug. 2017 – Juli 2021
G Pulla Reddy Engineering College, Kurnool, Indien